

UNIVERSIDAD MAYOR DE SAN ANDRÉS

CARRERA DE ESTADÍSTICA

MAESTRÍA EN CIENCIA Y ANÁLISIS DE DATOS VERSIÓN II

MÓDULO MINERÍA DE DATOS



TRABAJO DE INVESTIGACIÓN MINERÍA DE DATOS

DETECCIÓN Y CARACTERIZACIÓN DE COMPORTAMIENTOS ANÓMALOS EN REGISTROS OPERATIVOS DE UNA PLATAFORMA DE VENTAS MEDIANTE ISOLATION FOREST

AUTORES:

1. ROLANDO TROCHE VENEGAS
2. OSCAR ANTONIO RONDO RODRIGUEZ
3. GABRIEL ADRIAN MAZUELOS RABAZA

LA PAZ – BOLIVIA

2026

ÍNDICE

1	INTRODUCCIÓN	1
2	DIAGNÓSTICO Y PLANTEAMIENTO DEL PROBLEMA	2
2.1	PLANTEAMIENTO DEL PROBLEMA	4
3	OBJETIVO DE LA INVESTIGACIÓN	4
3.1	OBJETIVO GENERAL	4
3.2	OBJETIVOS ESPECÍFICOS	5
4	ANÁLISIS DE LA INFORMACIÓN	5
4.1	PREPARACIÓN DE LOS DATOS	5
4.2	FUENTE DE DATOS	8
4.3	PROCESO DE MODELADO	9
4.4	EVALUACIÓN	10
5	RESULTADOS	11
5.1	ANÁLISIS EXPLORATORIO DE DATOS	11
5.2	AJUSTE DEL HIPERPARÁMETRO CONTAMINATION	14
5.3	DESEMPEÑO DEL MODELO EN EL CONJUNTO DE TESTEO	15
5.4	VARIABLES CON MAYOR PODER DISCRIMINATIVO	17
5.5	CARACTERIZACIÓN DE LOS COMPORTAMIENTOS ANÓMALOS	19
5.6	DETECCIÓN POR SERVICIO	20
6	CONCLUSIONES	21
7	BIBLIOGRAFÍA	23

1 INTRODUCCIÓN

Los sistemas de software empresariales modernos registran de manera continua el comportamiento de cada transacción a través de archivos de *log*. En una plataforma de reportes de ventas, cada solicitud de un usuario atraviesa múltiples capas de servicio —desde el módulo de generación de reportes hasta la base de datos— dejando rastros detallados sobre tiempos de respuesta, volúmenes de datos procesados y uso de recursos computacionales (He et al., 2016). El análisis sistemático de estos registros constituye una fuente de inteligencia operativa invaluable para los equipos de tecnología.

Sin embargo, el volumen masivo de logs generados en producción hace inviable su inspección manual. Un sistema con 120 usuarios activos puede generar decenas de miles de entradas de log al mes, distribuidas en tres o más capas de servicio. En este contexto, la minería de datos ofrece mecanismos para automatizar la identificación de patrones inusuales, permitiendo que los sistemas de monitoreo alerten de manera proactiva sobre degradaciones de rendimiento, errores en cascada o comportamientos que ponen en riesgo la disponibilidad del servicio (Chandola et al., 2009).

La detección de anomalías no supervisada resulta especialmente adecuada para este dominio, ya que en entornos reales las instancias anómalas son escasas y raramente están etiquetadas con anticipación. El algoritmo *Isolation Forest* (Liu et al., 2008) se destaca en este campo porque no requiere una definición explícita de lo que constituye una anomalía: aprende la distribución del comportamiento normal y señala como anómalos aquellos registros que resultan difíciles de integrar en esa distribución.

El presente trabajo aplica *Isolation Forest* sobre 30 000 registros de logs de una plataforma de reportes de ventas compuesta por tres capas: *Report Service*, *Sales API* y base de datos. El objetivo central es no solo detectar los registros anómalos, sino también caracterizar los patrones que los distinguen del comportamiento normal, proporcionando información accionable sobre el tipo de problema que podría estar afectando al sistema.

2 DIAGNÓSTICO Y PLANTEAMIENTO DEL PROBLEMA

La plataforma de reportes de ventas analizada procesa solicitudes de usuarios con tres roles distintos —administrador, gerente y vendedor— que requieren cinco tipos de reportes: ventas diarias, ventas mensuales, ventas por producto, ventas por sucursal y ventas por cliente. Cada solicitud recorre el siguiente flujo de servicios:

Usuario → Report Service → Sales API → Base de Datos

Cada capa registra métricas operativas propias. El equipo de tecnología ha identificado que el sistema experimenta episodios periódicos de degradación que se manifiestan en incrementos abruptos de los tiempos de respuesta, aumento inusual en el volumen de datos procesados, elevación del consumo de CPU y memoria, y aparición de errores en la comunicación entre servicios. Estos episodios afectan la experiencia de los usuarios y, en casos extremos, provocan indisponibilidad del servicio.

La organización cuenta con registros históricos de logs pero carece de un mecanismo automatizado para detectar y caracterizar estos comportamientos anómalos. Las variables operativas disponibles son de naturaleza independiente —no existe una variable de respuesta predefinida durante la operación normal— lo que orienta el análisis hacia un **modelo de aprendizaje no supervisado**.

El conjunto de variables operativas disponibles incluye **10 variables numéricas independientes** (sin contar las variables tipo factor) que superan el mínimo requerido de 5 para modelos no supervisados:

1. **Tiempo de respuesta del servicio** (`response_time_ms`, ms): mide el tiempo total que tarda el servicio en procesar una solicitud. Es la causa directa de mala experiencia del usuario.
2. **Tiempo de consulta a la base de datos** (`db_query_time_ms`, ms): mide la latencia de las consultas SQL ejecutadas. Valores elevados indican ineficiencia en el motor de base de datos.
3. **Tiempo de respuesta de la Sales API** (`api_response_time_ms`, ms): latencia de la capa intermedia. Incluye el tiempo de consulta a BD más la lógica de negocio propia de la API.
4. **Registros retornados** (`records_returned`, unidades): cantidad de filas de datos incluidas en el reporte. Valores extremadamente altos pueden señalar exportaciones masivas no autorizadas.
5. **Filas escaneadas en BD** (`rows_scanned`, unidades): número de filas que el motor de base de datos procesó para generar el resultado. Una alta relación filas escaneadas / registros retornados indica consultas ineficientes.
6. **Tamaño del reporte generado** (`report_size_kb`, KB): tamaño del archivo de salida. Relacionado con el número de registros y la complejidad del reporte.
7. **Uso de CPU del servicio** (`cpu_usage_percent`, %): porcentaje de CPU consumido durante el procesamiento de la solicitud.
8. **Uso de memoria RAM** (`memory_usage_mb`, MB): memoria consumida durante el procesamiento de la solicitud.

9. **Número de reintentos** (`retry_count`, unidades): cantidad de veces que la solicitud fue reintentada por fallos. Valores mayores a 1 indican inestabilidad.
10. **Número de errores registrados** (`error_count`, unidades): errores generados durante el procesamiento de la solicitud.

Adicionalmente, el conjunto incluye **variables tipo factor**: `service` (servicio que generó el log), `report_type` (tipo de reporte) y `user_role` (rol del usuario), que se incorporan al modelo mediante codificación numérica.

2.1. PLANTEAMIENTO DEL PROBLEMA

Pregunta de investigación

¿La aplicación del algoritmo *Isolation Forest* sobre los registros operativos de la plataforma de ventas —que integra los servicios *Report Service*, *Sales API* y base de datos— permitirá detectar y caracterizar comportamientos anómalos en las métricas de rendimiento del sistema, identificando potenciales problemas de disponibilidad y degradación del servicio?

3 OBJETIVO DE LA INVESTIGACIÓN

3.1. OBJETIVO GENERAL

Detectar y caracterizar comportamientos anómalos en los registros operativos de una plataforma de ventas mediante la aplicación del algoritmo *Isolation Forest*, con el propósito de identificar potenciales problemas de rendimiento y disponibilidad del sistema.

3.2. OBJETIVOS ESPECÍFICOS

1. Describir las características estadísticas y distribuciones de las variables operativas del sistema de reportes de ventas para identificar los rangos de comportamiento normal en los tres servicios de la plataforma.
2. Construir un modelo de detección de anomalías basado en el algoritmo *Isolation Forest*, ajustando el hiperparámetro *contamination* mediante el conjunto de validación para maximizar el F1-Score.
3. Evaluar el desempeño del modelo sobre el conjunto de testeo utilizando las métricas AUC-ROC, F1-Score, precisión y recall.
4. Caracterizar los comportamientos anómalos detectados por el modelo, identificando los tipos de anomalías más frecuentes y las variables operativas con mayor poder discriminativo.

4 ANÁLISIS DE LA INFORMACIÓN

4.1. PREPARACIÓN DE LOS DATOS

El conjunto de datos fue examinado en su totalidad antes de aplicar cualquier transformación. La Tabla 4.1 describe cada variable, su tipo, unidad de medida y el tratamiento aplicado.

Variable	Tipo	Unidad	Descripción	Transformación
timestamp	Fecha/hora	ISO 8601	Marca temporal del evento	Extracción de hora del día (hour)
trace_id	ID	–	Identificador único de la traza	No incluida en el modelo
service	Factor nominal	–	Servicio que generó el log	<i>Label Encoding</i>
user_hash	ID anonimizado	–	Identificador del usuario (anonimizado)	No incluida en el modelo
tenant_hash	ID anonimizado	–	Identificador de la empresa (anonimizado)	No incluida en el modelo
user_role	Factor nominal	–	Rol del usuario	<i>Label Encoding</i>
report_type	Factor nominal	–	Tipo de reporte solicitado	<i>Label Encoding</i>
status_code	Discreta	–	Código de estado HTTP	No incluida en el modelo
response_time_ms	Continua	ms	Tiempo de respuesta total del servicio	Estandarización (z-score)
db_query_time_ms	Continua	ms	Tiempo de consulta a la base de datos	Estandarización (z-score)
api_response_time_ms	Continua	ms	Tiempo de respuesta de la Sales API	Estandarización (z-score)
records_returned	Discreta	registros	Cantidad de registros retornados	Estandarización (z-score)

Variable	Tipo	Unidad	Descripción	Transformación
rows_scanned	Discreta	filas	Filas escaneadas en la BD	Estandarización (z-score)
report_size_kb	Continua	KB	Tamaño del reporte generado	Estandarización (z-score)
cpu_usage_percent	Continua	%	Uso de CPU del servicio	Estandarización (z-score)
memory_usage_mb	Continua	MB	Uso de memoria RAM	Estandarización (z-score)
retry_count	Discreta	reintentos	Número de reintentos de la solicitud	Estandarización (z-score)
error_count	Discreta	errores	Errores generados durante el procesamiento	Estandarización (z-score)

Tabla 4.1: Descripción y tratamiento de las variables del conjunto de datos.

Valores faltantes. Al parsear las marcas temporales, un subconjunto de registros con variaciones de formato produjo valores nulos en las características extraídas (hour). Estos valores se imputaron con cero, lo que no afecta el análisis dado que representan menos del 0,01 % del total.

Tratamiento de valores extremos. El conjunto de datos contiene valores extremos en las variables de tiempo de respuesta, registros retornados y uso de memoria. Estos valores extremos **no fueron eliminados**, dado que corresponden precisamente a los comportamientos anómalos objeto de estudio. Su presencia es coherente con los cuatro tipos de anomalías conocidos y su retención es necesaria para que el modelo pueda aprender a distinguirlos del comportamiento normal.

Transformaciones. Las 10 variables numéricas y la variable hour fueron estandariza-

das mediante el método *StandardScaler* ($\mu = 0$, $\sigma = 1$), de modo que todas contribuyan por igual al algoritmo sin importar su escala original. Las tres variables tipo factor (*service*, *report_type*, *user_role*) fueron convertidas a enteros mediante *Label Encoding*. El vector de características final tiene **14 dimensiones**.

El análisis estadístico descriptivo de las principales variables en el servicio *report-service* se presenta en la Tabla 4.2.

Variable	Media	Desv. Est.	Mín.	Mediana	Máx.
T. respuesta (ms)	3 995,77	5 021,09	933	3 084	96 135
T. consulta BD (ms)	1 429,42	2 236,65	128	1 074	60 700
T. respuesta API (ms)	1 808,73	2 440,78	270	1 441	61 712
Registros retornados	5 820,12	15 222,27	100	3 990	424 502
Filas escaneadas	31 122,15	106 800,62	224	17 149	3 647 680
Tamaño reporte (KB)	2 378,51	8 696,68	16	1 305	288 490
CPU (%)	43,21	13,96	20,00	42,91	98,91
Memoria (MB)	782,54	537,64	250	738	8 330
Reintentos	0,30	0,60	0	0	6
Errores	0,03	0,33	0	0	5

Tabla 4.2: Estadísticas descriptivas del servicio *report-service* ($n = 10\,000$).

La elevada desviación estándar respecto a la media en variables como el tiempo de respuesta ($\text{std}/\text{media} \approx 1,26$) y los registros retornados ($\text{std}/\text{media} \approx 2,61$) confirma la presencia de valores extremos producidos por los comportamientos anómalos, que en la práctica se traducen en degradación del servicio percibida por el usuario.

4.2. FUENTE DE DATOS

Los datos utilizados en este trabajo provienen de los registros operativos de una **plataforma privada de ventas empresarial**, cuyos logs fueron anonimizados antes de su análisis. En cumplimiento con los principios de protección de datos, los identificadores sensibles fueron sustituidos por su función hash unidireccional:

- **Usuarios:** reemplazados por `user_hash` (formato: `user_NNN`).
- **Empresas/Tenants:** reemplazados por `tenant_hash` (formato: `tenant_NNN`).
- **Identificadores de traza:** generados mediante UUID truncado (`trace_id`), sin relación con identificadores internos del sistema.

El conjunto de datos comprende **30 000 registros** de logs recopilados durante el mes de enero de 2026, distribuidos uniformemente entre tres servicios (10 000 registros cada uno). Estos registros corresponden a **10 000 trazas únicas**, cada una representando una transacción completa de usuario a base de datos. El sistema registra actividad de **120 usuarios únicos** distribuidos en **20 tenants**.

4.3. PROCESO DE MODELADO

Método y tarea. Se empleó el algoritmo **Isolation Forest** (Liu et al., 2008, 2012), un método de aprendizaje no supervisado diseñado específicamente para la detección de anomalías. Su fundamento es el principio de *aislamiento*: las anomalías son instancias atípicas que se aíslan con mayor facilidad que las instancias normales al particionar aleatoriamente el espacio de características. El algoritmo construye un conjunto de T *árboles de aislamiento* (*isolation trees*) y asigna a cada instancia una puntuación de anomalía basada en la profundidad media a la que es aislada:

$$s(x, n) = 2^{-\frac{E[h(x)]}{c(n)}} \quad (4.1)$$

donde $h(x)$ es la longitud del camino de aislamiento de la instancia x , $c(n) = 2H(n - 1) - \frac{2(n-1)}{n}$ es el factor de normalización (siendo H la función armónica), y $E[\cdot]$ es el promedio sobre todos los árboles. Valores de s cercanos a 1 indican anomalía; cercanos a 0 indican normalidad.

Partición de los datos. El conjunto de datos fue dividido en tres subconjuntos mediante muestreo estratificado (manteniendo la proporción de anomalías en cada partición):

Conjunto	Registros	Anomalías	Uso
Entrenamiento (70 %)	21 000	956 (4,55 %)	Ajuste del modelo
Validación (15 %)	4 500	205 (4,56 %)	Ajuste de hiperparámetros
Testeo (15 %)	4 500	204 (4,53 %)	Evaluación final
Total	30 000	1 365 (4,55 %)	

Tabla 4.3: Partición del conjunto de datos.

Hiperparámetros. El modelo fue entrenado con los siguientes parámetros:

Hiperparámetro	Valor	Descripción
n_estimators	200	Número de árboles de aislamiento en el conjunto.
contamination	0,04 (ajustado)	Proporción esperada de anomalías. Se probaron valores entre 0,03 y 0,08 sobre el conjunto de validación; el valor 0,04 maximizó el F1-Score.
max_samples	auto (256)	Número de muestras utilizadas para construir cada árbol.
random_state	42	Semilla de aleatoriedad para reproducibilidad.

Tabla 4.4: Hiperparámetros del modelo Isolation Forest.

4.4. EVALUACIÓN

Para medir la calidad del modelo sobre el conjunto de **testeo**, se emplearon los siguientes indicadores (Fawcett, 2006):

- **AUC-ROC** (*Area Under the ROC Curve*): área bajo la curva que relaciona la tasa de verdaderos positivos (TPR) con la tasa de falsos positivos (FPR) para todos

los umbrales posibles. Mide la capacidad discriminativa del modelo de manera independiente del umbral, con valores entre 0,5 (aleatorio) y 1,0 (perfecto).

- **Precisión:** fracción de los registros predichos como anomalía que efectivamente son anomalías. $\text{Precisión} = TP / (TP + FP)$.
- **Recall** (sensibilidad): fracción de las anomalías reales que fueron correctamente detectadas. $\text{Recall} = TP / (TP + FN)$.
- **F1-Score:** media armónica entre precisión y recall. $F1 = 2 \cdot \text{Precisión} \cdot \text{Recall} / (\text{Precisión} + \text{Recall})$. Métrica principal de ajuste de hiperparámetros dado el desbalance de clases.
- **Matriz de confusión:** tabla de contingencia con los conteos de verdaderos positivos (TP), verdaderos negativos (TN), falsos positivos (FP) y falsos negativos (FN).

5 RESULTADOS

5.1. ANÁLISIS EXPLORATORIO DE DATOS

El conjunto de datos contiene 30 000 registros con una tasa de anomalías del 4,55 % (1 365 registros anómalos). Se identificaron cuatro tipos de comportamiento anómalo, distribuidos de manera similar entre los tres servicios de la plataforma (Figura 1).




Figura 1: Distribución de tipos de anomalía: global (izquierda) y por servicio (derecha).

Las consultas lentas a la base de datos (*slow_database_query*) son el tipo más frecuente (399 registros, 29,2% del total de anomalías), seguidas por alto uso de recursos (339, 24,8%), exportaciones de gran tamaño (315, 23,1%) y alta tasa de errores (312, 22,9%). La distribución uniforme entre servicios es coherente con la propagación de anomalías a lo largo de toda la cadena de transacción.

La Figura 2 muestra los diagramas de caja del tiempo de respuesta y tiempo de consulta a BD por tipo de anomalía.




Figura 2: Distribución de tiempos por tipo de anomalía en *report-service*.

Las consultas lentas a BD producen los tiempos de respuesta más elevados (valores máximos superiores a 96 000 ms, equivalentes a 96 segundos), seguidas por las exportacio-

nes de gran tamaño. La Figura 3 muestra las correlaciones entre variables, donde destaca la alta asociación entre los tres tiempos de respuesta ($r > 0,9$), coherente con su relación en cascada.




Figura 3: Matriz de correlación de variables numéricas (*report-service*).

La Figura 4 muestra que la tasa de anomalías es estable a lo largo del día (oscila alrededor del 4,5%), descartando concentraciones temporales y sugiriendo causas sistémicas.




Figura 4: Distribución temporal de registros y tasa de anomalías por hora.

5.2. AJUSTE DEL HIPERPARÁMETRO CONTAMINATION

La Figura 5 muestra el F1-Score obtenido en el conjunto de validación para cada valor candidato del parámetro *contamination*.




Figura 5: F1-Score en validación vs. parámetro *contamination*.

El valor óptimo fue $\text{contamination} = 0,04$, que produjo el F1-Score más alto en validación ($F1 = 0,6785$). Este valor es ligeramente inferior a la tasa real de anomalías (4,55%), indicando que el modelo prefiere ser más conservador en sus predicciones, priorizando la precisión sobre el recall.

5.3. DESEMPEÑO DEL MODELO EN EL CONJUNTO DE TESTEO

Los resultados sobre el conjunto de testeo (4 500 registros, 204 anomalías reales) se presentan en la Tabla 5.1.

Métrica	Valor (testeo)
AUC-ROC	0,9696
F1-Score	0,7016
Precisión	0,7528
Recall	0,6569
Verdaderos positivos (TP)	134
Verdaderos negativos (TN)	4 252
Falsos positivos (FP)	44
Falsos negativos (FN)	70

Tabla 5.1: Métricas de desempeño del modelo Isolation Forest en el conjunto de testeo.

El AUC-ROC de 0,9696 indica una capacidad discriminativa excelente: el modelo es capaz de separar eficazmente los registros normales de los anómalos mediante sus puntuaciones de anomalía continuas (Figura 6).




Figura 6: Curva ROC del modelo Isolation Forest sobre el conjunto de testeo.

La distribución de las puntuaciones de anomalía (Figura 7) confirma que el modelo asigna puntuaciones claramente más elevadas a los registros anómalos, aunque existe una región de solapamiento que explica los 44 falsos positivos y 70 falsos negativos.




Figura 7: Distribución de puntuaciones de anomalía: registros normales vs. anómalos.

La matriz de confusión (Figura 8) muestra que el modelo clasifica correctamente el 65,7 % de las anomalías reales (134 de 204) y el 99,0 % de los registros normales (4 252 de 4 296), con una tasa de falsa alarma del 1,0 %.




Figura 8: Matriz de confusión del modelo Isolation Forest (conjunto de testeo).

5.4. VARIABLES CON MAYOR PODER DISCRIMINATIVO

El análisis de importancia por permutación (Figura 9) revela las variables que más contribuyen a la detección de anomalías.




Figura 9: Importancia de variables por permutación — Isolation Forest.

Las cinco variables con mayor importancia son:

1. **Tiempo de respuesta de la API** (`api_response_time_ms`): importancia = 0,003212.
2. **Tiempo de respuesta total** (`response_time_ms`): importancia = 0,003139.
3. **Registros retornados** (`records_returned`): importancia = 0,002607.
4. **Tamaño del reporte** (`report_size_kb`): importancia = 0,002550.
5. **Hora del día** (`hour`): importancia = 0,002462.

Las dos variables de tiempo de respuesta dominan porque son sensibles a múltiples tipos de anomalía simultáneamente. Las variables de volumen (registros y tamaño de reporte) son específicamente discriminativas para las exportaciones de gran tamaño.

5.5. CARACTERIZACIÓN DE LOS COMPORTAMIENTOS ANÓMALOS

La Figura 10 muestra el perfil de cada tipo de anomalía expresado como la razón entre el valor medio de cada variable en el grupo anómalo y el valor medio en el grupo normal. Un valor de razón igual a 1 indica comportamiento idéntico al normal; valores superiores indican incrementos proporcionales.




Figura 10: Perfil de anomalías: ratio de variables respecto al comportamiento normal.

La caracterización revela patrones distintivos para cada tipo:

- **DB lenta (*slow_database_query*):** incremento entre 8 y 20 veces en el tiempo de consulta a BD y en las filas escaneadas. Los tiempos de respuesta de la API y del servicio escalan proporcionalmente. Señal de alerta: $T_{BD} > 10000$ ms.
- **Exportación grande (*large_report_export*):** incremento de 10 a 30 veces en el número de registros retornados y en el tamaño del reporte. La memoria consumida se multiplica por 3 a 6. Señal de alerta: $records_returned > 50\,000$.
- **Alta tasa de errores (*high_error_rate*):** incremento drástico en el conteo de errores (hasta 5 errores por solicitud) y en el número de reintentos (hasta 6). Señal de alerta: $error_count > 0$ y $retry_count > 1$.

- **Alto uso de recursos (*high_resource_usage*):** CPU entre 85 % y 99 % (ratio $\approx 2,1$) y memoria multiplicada por 3 a 7 respecto al valor normal. Señal de alerta: $cpu_usage_percent > 85\%$.

5.6. DETECCIÓN POR SERVICIO

La Figura 11 muestra el número de anomalías reales, detectadas y verdaderos positivos por servicio sobre el conjunto completo de 30 000 registros.




Figura 11: Anomalías reales, detectadas y verdaderos positivos por servicio.

El modelo mantiene un comportamiento consistente en los tres servicios, detectando proporciones similares de anomalías en cada capa. Dado que las anomalías se propagan a lo largo de toda la cadena de transacción, cada anomalía genera registros anómalos en los tres servicios simultáneamente, lo que permite al modelo detectarla desde cualquier

capa.

6 CONCLUSIONES

Las siguientes conclusiones responden a cada objetivo específico planteado y se vinculan al problema de investigación central:

1. **Respecto a describir las características estadísticas del comportamiento normal (Objetivo Específico 1):** El análisis exploratorio reveló que, en condiciones normales, el tiempo de respuesta del *Report Service* se sitúa entre 933 ms y 3 754 ms (percentiles 0 y 75), con una mediana de 3 084 ms. Las variables de tiempo presentan altas correlaciones entre sí ($r > 0,9$), lo que confirma la naturaleza en cascada del sistema. La tasa de anomalías es estable a lo largo del día ($\approx 4,5\%$), descartando dependencias temporales y apuntando a causas sistémicas. Este conocimiento del comportamiento normal es el insumo clave para la construcción del modelo de detección.
2. **Respecto a construir el modelo Isolation Forest (Objetivo Específico 2):** El modelo fue construido exitosamente con 14 variables de entrada, entrenado sobre 21 000 registros y ajustado mediante 8 valores candidatos de *contamination* evaluados en el conjunto de validación. El valor óptimo ($\text{contamination} = 0,04$) maximizó el F1-Score de validación (0,6785), priorizando la precisión sobre el recall al ser conservador en la declaración de anomalías, lo cual es adecuado en contextos operacionales donde las falsas alarmas tienen costos relevantes.
3. **Respecto a evaluar el desempeño en testeo (Objetivo Específico 3):** El modelo alcanzó un **AUC-ROC de 0,9696** sobre el conjunto de testeo independiente (4 500

registros), evidenciando una capacidad discriminativa excelente. El F1-Score de 0,7016 con una precisión de 0,7528 y un recall de 0,6569 indica que de cada 100 alertas generadas por el modelo, 75 son anomalías reales, y el modelo detecta el 65,7 % del total de anomalías presentes. La tasa de falsa alarma es del 1,0 % (44 falsos positivos sobre 4 296 registros normales), nivel aceptable para un sistema de monitoreo en producción. Estos resultados responden afirmativamente a la pregunta de investigación: el algoritmo Isolation Forest sí permite detectar comportamientos anómalos en los registros de la plataforma.

4. **Respecto a caracterizar los comportamientos anómalos (Objetivo Específico 4):** El análisis de perfiles reveló que cada tipo de anomalía deja una firma estadística distintiva en las variables operativas. Las consultas lentas a la base de datos elevan el tiempo de consulta BD entre 8 y 20 veces; las exportaciones grandes incrementan el volumen de registros en 10 a 30 veces; la alta tasa de errores se distingue por valores no nulos en *error_count* y *retry_count*; y el alto uso de recursos eleva el CPU por encima del 85 %. Las variables con mayor poder discriminativo son los tiempos de respuesta (*api_response_time_ms* y *response_time_ms*) y las variables de volumen (*records_returned* y *report_size_kb*), información que permite diseñar umbrales de alerta específicos para cada tipo de problema de disponibilidad o rendimiento.

En conclusión, la aplicación de *Isolation Forest* sobre los registros operativos de la plataforma de ventas demostró ser una herramienta efectiva para la detección automatizada y caracterización de comportamientos anómalos, con potencial de implementación como sistema de monitoreo en tiempo real para identificar oportunamente problemas de

rendimiento y disponibilidad.

7 BIBLIOGRAFÍA

Bibliografía

Chandola, V., Banerjee, A., and Kumar, V. (2009). Anomaly detection: A survey. In *ACM Computing Surveys*, volume 41, pages 1–58. ACM.

Fawcett, T. (2006). An introduction to ROC analysis. *Pattern Recognition Letters*, 27(8):861–874.

He, P., Zhu, J., He, S., Li, J., and Lyu, M. R. (2016). An evaluation study on log parsing and its use in log mining. In *2016 46th Annual IEEE/IFIP International Conference on Dependable Systems and Networks*, pages 654–661. IEEE.

Liu, F. T., Ting, K. M., and Zhou, Z.-H. (2008). Isolation forest. In *2008 Eighth IEEE International Conference on Data Mining*, pages 413–422. IEEE.

Liu, F. T., Ting, K. M., and Zhou, Z.-H. (2012). Isolation-based anomaly detection. *ACM Transactions on Knowledge Discovery from Data*, 6(1):1–39.